Projekt, Inteligencja Obliczeniowa

Operacje na tekście na przykładzie analizy piosenek

Marta Leszczyńska,
nr indeksu 234325
Informatyka II, niestacjonarne

1. Wybór i przygotowanie danych do dalszej analizy

Baza danych, na której przeprowadzona została niniejsza analiza tekstu, pochodzi kaggle.com: 55000+ Song Lyrics . Dane zostały pozyskane za pomocą metody web - scraping'u. Pierwotna baza zawierała ponad 55000 rekordów (piosenek) pogrupowanych alfabetycznie według zespołów. Baza została przeze mnie podzielona na pliki .csv o długościach po 1 000 rekordów, z czego do niniejszego projektu wykorzystano i przetworzono 14 plików po 1000 rekordów. Wyniki zaprezentowane w dalszych częściach projektu to przykłady analizy poszczególnych autorów i ich piosenek.

Pierwszym krokiem było pogrupowanie piosenek względem zespołów, co zostało zrealizowane automatycznie w języku Python, podobnie jak reszta operacji. Następnie, otrzymane wyniki zostały poddane tokenizacji oraz lemmatyzacji, przy pomocy pakietu NLTK. Na potrzeby innych operacji, pliki zostały również poddane łączeniu piosenek dla zespołów.

Na każdym etapie obróbki danych należało zapisać wyniki do pliku .pkl, z uwagi na długi czas wykonywania poszczególnych operacji. Długi czas przetwarzania wynikał z iterowania słowo po słowie każdej piosenki każdego zespołu.

```
def get_data(filepath):
    data = []
    file = open(filepath)
    csv_file = csv.reader(file)

    for row in csv_file:
        data.append(row)

    return data


def get_artists_dict(data):

    dict = {}
    for row in data:
        dict[row[index_artist]] = []
    for row in data:
        dict[row[index_artist]].append(row[index_text])
    return dict


def save_object_to_file(object, name):
    with open(objects_repo_location + name, 'wb') as file:
        pickle.dump(object, file, pickle.HIGHEST_PROTOCOL)


def load_object(name):
    with open(objects_repo_location + name, 'rb') as file:
        return pickle.load(file)
```

Metody przetwarzania, zapisu do pliku .pkl i jego odczytu

```python
def tokenize_dict(dict_to_tokenize):
    tokenized_dict = {}
    for key, value in dict_to_tokenize.items():
        song_texts_list_for_one_artist = value
        artist_name = key
        tokenized_texts_list_for_one_artist = []
        for song_text in song_texts_list_for_one_artist:
            song_text_without_line_breaks = song_text.replace("\n", " ")
            tokenized_text = word_tokenize(song_text_without_line_breaks)
            tokenized_texts_list_for_one_artist.append(tokenized_text)
        tokenized_dict[artist_name] = tokenized_texts_list_for_one_artist
    return tokenized_dict


def lemmatize_dict(tokenized_dict):
    lem = WordNetLemmatizer()
    lemmatized_dict = {}
    for key, value in tokenized_dict.items():
        tokenized_songs = value
        artist_name = key
        lemmatized_song_texts = []
        for tokenized_song in tokenized_songs:
            lemmatized_song = [lem.lemmatize(word, get_wordnet_pos(word)) for word in tokenized_song]
            lemmatized_song_texts.append(lemmatized_song)
        lemmatized_dict[artist_name] = lemmatized_song_texts
    return lemmatized_dict
```

Metody tokenizacji i lemmatyzacji

2. Chmury najczęstszych słów

Dla każdego artysty dokonano analizy najczęściej używanych słów i zwizualizowano wyniki jako chmury tych słów. Użyto do tego pakietu WordCloud.

Chmura najczęstszych słów zespołu The Betles

Chmura najczęstszych słów Michael'a Jackson'a

```python
def create_wordcloud(dict_to_create_wordcloud):

    for key, value in dict_to_create_wordcloud.items():
        artist = key
        text = value
        text_list = []
        for data in text:
            word = data[0]
            freq = data[1]
            for i in range(freq):
                text_list.append(word)
        new_text = ' '.join(text_list)

        wordcloud = WordCloud(collocations=False, background_color="white", max_font_size=50, max_words=100).generate(new_text)
        wordcloud.to_file("/Users/reckony/Desktop/UGSTUDIA/IOproject/Wordclouds/" + f'Wordcloud_{artist}.png')
    return True
```

Metoda tworząca chmury słów i zapisująca je do pliku

3. Podobieństwo zespołów

Do określenia podobieństw między zespołami wykorzystano podobieństwo cosinusowe. Przykładowy graf został stworzony przy pomocy paczki networkx. Jako węzły podano nazwy zespołów, natomiast miara podobieństwa cosinusowego podano jako wagę połączenia.

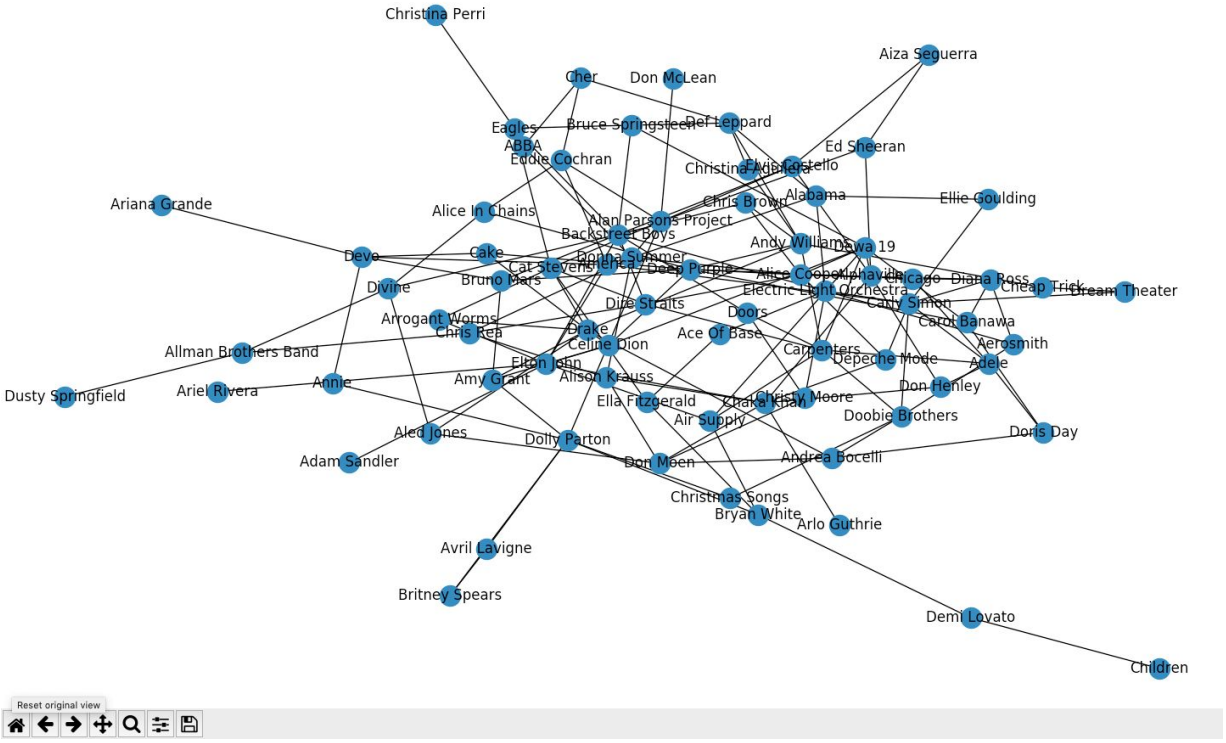

Graf podobieństwa dla wybranych zespołów

```python
def get_cosine_similarity(tokenized_filtered_text1, tokenized_filtered_text2):
    text1 = []
    text2 = []
    text1_tokenized = word_tokenize(tokenized_filtered_text1)
    text2_tokenized = word_tokenize(tokenized_filtered_text2)
    sw = stopwords.words('english')

    text1_set = {w for w in text1_tokenized if not w in sw}
    text2_set = {w for w in text2_tokenized if not w in sw}

    rvector = text1_set.union(text2_set)
    for w in rvector:
        if w in text1_set:
            text1.append(1)  # create a vector
        else:
            text1.append(0)
        if w in text2_set:
            text2.append(1)
        else:
            text2.append(0)

    c = 0
    # cosine formula
    for i in range(len(rvector)):
        c += text1[i] * text2[i]
    cosine = c / float((sum(text1) * sum(text2)) ** 0.5)

    return cosine
```

Metoda obliczająca podobieństwo cosinusowe

4. Wydobywanie tematu piosenek

Do wydobywania tematów piosenek użyto pakietu gensim. Za jego pomocą zbudowany został model LdaModel, który szukał 5 tematów w zdaniach. Dzięki wynikom możemy domyślić się, o czym jest sana piosenka, nie czytając/słuchając jej.

```
Foreigner, Mointain of love:

('0.161*"honey" + 0.057*"touch" + 0.057*"baby" + 0.055*"feel" + 0.031*"pretendin"')
('0.139*"high" + 0.095*"little" + 0.072*"build" + 0.050*"edge" + 0.050*"\'cause"')
('0.268*"love" + 0.255*"mountain" + 0.056*"climb" + 0.042*"risin"+ 0.068*"good")


Gloria Estefan, Along came you:

('0.241*"love" + 0.156*"baby" + 0.139*"come" + 0.088*"yes" + 0.037*"certain"')
('0.168*"along" + 0.127*"oh" + 0.127*"thula" + 0.066*"show" + 0.045*"angel"')
('0.240*"know" + 0.124*"knew" + 0.047*"apart" + 0.047*"live" + 0.047*"look"')


Glee, Away in a manger
('0.175*"directions" + 0.092*"love" + 0.092*"kitty" + 0.050*"baby" + 0.050*"bed"')
('0.208*"lord" + 0.088*"sky" + 0.088*"stay" + 0.048*"morning" + 0.048*"cattle"')
('0.140*"new" + 0.107*"little" + 0.073*"look" + 0.040*"head" + 0.040*"hay"')
```

Porównanie tematów wybranych piosenek

Możemy zauważyć, że zarówno piosenka zespołu Foreigner, Glorii Estefan oraz Glee, są o miłości.

```
Gloria Estefan, Bad Boy:

('0.100*"drive" + 0.100*"right" + 0.100*"heart" + 0.100*"oh" + 0.100*"phone"')
('0.641*"boy" + 0.107*"nothin" + 0.072*"good" + 0.038*"go" + 0.021*"night"'),
('0.632*"bad" + 0.052*"breathless" + 0.052*"gettin" + 0.052*"always" + 0.052*"restless"')


Glee, Cool:

('0.356*"cool" + 0.096*"easy" + 0.096*"loose" + 0.096*"breeze" + 0.052*"take"'),
('0.169*"got" + 0.092*"school" + 0.092*"coolie" + 0.092*"like" + 0.092*"high"')
('0.423*"boy" + 0.121*"crazy" + 0.051*"buzz" + 0.051*"get" + 0.051*"turn"')
```

Porównanie tematów wybranych piosenek

Natomiast powyższe dwie piosenki dotyczą młodości, spontaniczności.

```python
def get_main_topics(dict_to_check):
    topics_dict = {}
    for key, value in dict_to_check.items():
        artist = key
        songs = value
        songs_topic_list = []
        for song in songs:
            song1 = [d.split() for d in song1]
            dictionary = corpora.Dictionary(song1)
            corpus = [dictionary.doc2bow(text) for text in song1]
            ldamodel = gensim.models.ldamodel.LdaModel(corpus, num_topics=NUM_TOPICS, id2word=dictionary, passes=15)
            topics = ldamodel.print_topics(num_words=5)
            songs_topic_list.append(songs.index(song))
            songs_topic_list.append(topics)
        topics_dict[artist] = songs_topic_list
    return topics_dict
```

Metoda szukania tematów w tekście

5. Prawo Zipfa

Ostatnią analizą przeprowadzoną na piosenkach jest sprawdzenie, czy zachodzi w nich prawo Zipfa. Prawo to głosi, że ranga słowa i częstotliwość jego występowania pomnożone przez siebie, powinny stanowić constans. Patrząc na poniższe wyniki można zauważyć, że odchylenia między poszczególnymi słowami jest dosyć spore.

Rank	Word	Actual Freq	Zipf Frac	Zipf Freq	Actual Diff	Pct Diff
1	know	104	1/1	104.00	0.00	100.00%
2	come	87	1/2	52.00	35.00	167.31%
3	yeah	85	1/3	34.67	50.33	245.19%
4	love	75	1/4	26.00	49.00	288.46%
5	never	67	1/5	20.80	46.20	322.12%
6	want	62	1/6	17.33	44.67	357.69%
7	could	62	1/7	14.86	47.14	417.31%
8	like	52	1/8	13.00	39.00	400.00%
9	time	48	1/9	11.56	36.44	415.38%
10	when	42	1/10	10.40	31.60	403.85%
11	life	42	1/11	9.45	32.55	444.23%
12	ever	41	1/12	8.67	32.33	473.08%
13	lost	41	1/13	8.00	33.00	512.50%
14	world	38	1/14	7.43	30.57	511.54%
15	feel	38	1/15	6.93	31.07	548.08%
16	always	38	1/16	6.50	31.50	584.62%
17	light	34	1/17	6.12	27.88	555.77%
18	every	34	1/18	5.78	28.22	588.46%
19	what	34	1/19	5.47	28.53	621.15%
20	cause	33	1/20	5.20	27.80	634.62%
21	rain	33	1/21	4.95	28.05	666.35%
22	nothing	32	1/22	4.73	27.27	676.92%
23	find	30	1/23	4.52	25.48	663.46%
24	that	30	1/24	4.33	25.67	692.31%
25	would	29	1/25	4.16	24.84	697.12%
26	eyes	29	1/26	4.00	25.00	725.00%
27	right	28	1/27	3.85	24.15	726.92%
28	going	28	1/28	3.71	24.29	753.85%
29	everything	28	1/29	3.59	24.41	780.77%
30	just	28	1/30	3.47	24.53	807.69%
31	arms	27	1/31	3.35	23.65	804.81%
32	maybe	26	1/32	3.25	22.75	800.00%
33	live	25	1/33	3.15	21.85	793.27%
34	feeling	25	1/34	3.06	21.94	817.31%
35	away	24	1/35	2.97	21.03	807.69%
36	back	24	1/36	2.89	21.11	830.77%
37	hear	23	1/37	2.81	20.19	818.27%
38	sing	22	1/38	2.74	19.26	803.85%
39	good	22	1/39	2.67	19.33	825.00%
40	came	22	1/40	2.60	19.40	846.15%
41	around	21	1/41	2.54	18.46	827.88%
42	things	21	1/42	2.48	18.52	848.08%
43	water	21	1/43	2.42	18.58	868.27%
44	look	21	1/44	2.36	18.64	888.46%

Prawo Zipfa dla zespołu Coldplay

Rank	Word	Actual Freq	Zipf Frac	Zipf Freq	Actual Diff	Pct Diff
1	never	57	1/1	57.00	0.00	100.00%
2	hell	43	1/2	28.50	14.50	150.88%
3	take	42	1/3	19.00	23.00	221.05%
4	united	40	1/4	14.25	25.75	280.70%
5	love	39	1/5	11.40	27.60	342.11%
6	know	35	1/6	9.50	25.50	368.42%
7	night	32	1/7	8.14	23.86	392.98%
8	last	32	1/8	7.12	24.88	449.12%
9	like	31	1/9	6.33	24.67	489.47%
10	blood	29	1/10	5.70	23.30	508.77%
11	come	28	1/11	5.18	22.82	540.35%
12	want	26	1/12	4.75	21.25	547.37%
13	time	25	1/13	4.38	20.62	570.18%
14	around	24	1/14	4.07	19.93	589.47%
15	sinner	24	1/15	3.80	20.20	631.58%
16	rose	24	1/16	3.56	20.44	673.68%
17	stand	23	1/17	3.35	19.65	685.96%
18	summer	21	1/18	3.17	17.83	663.16%
19	give	20	1/19	3.00	17.00	666.67%
20	inside	20	1/20	2.85	17.15	701.75%
21	that	20	1/21	2.71	17.29	736.84%
22	away	19	1/22	2.59	16.41	733.33%
23	life	19	1/23	2.48	16.52	766.67%
24	fall	19	1/24	2.38	16.62	800.00%
25	when	18	1/25	2.28	15.72	789.47%
26	stained	17	1/26	2.19	14.81	775.44%
27	hand	17	1/27	2.11	14.89	805.26%
28	eyes	16	1/28	2.04	13.96	785.96%
29	fire	16	1/29	1.97	14.03	814.04%
30	hear	16	1/30	1.90	14.10	842.11%
31	found	16	1/31	1.84	14.16	870.18%
32	bent	16	1/32	1.78	14.22	898.25%
33	cause	16	1/33	1.73	14.27	926.32%
34	world	15	1/34	1.68	13.32	894.74%
35	every	15	1/35	1.63	13.37	921.05%
36	saints	15	1/36	1.58	13.42	947.37%
37	feel	15	1/37	1.54	13.46	973.68%
38	fear	14	1/38	1.50	12.50	933.33%
39	light	14	1/39	1.46	12.54	957.89%
40	with	14	1/40	1.43	12.57	982.46%
41	death	14	1/41	1.39	12.61	1007.02%
42	savage	14	1/42	1.36	12.64	1031.58%
43	what	13	1/43	1.33	11.67	980.70%
44	better	13	1/44	1.30	11.70	1003.51%
45	near	13	1/45	1.27	11.73	1026.32%

Prawo Zipfa dla zespołu Judas Priest

Przykład analizy prawa Zipfa: weźmy zespół Coldplay, jego 10, 20 oraz 30 słowo w rankingu.
Wynik równania Estoupa - Zipfa:
Dla 10 słowa: 10 * 42 = 420
Dla 20 słowa: 20 * 33 = 660
Dla 30 słowa: 30 * 28 = 840
Wynik równania dla wszystkich powyższych powinien być taki sam, natomiast różnica między wynikami jest spora.

Rank	Word	Actual Freq	Zipf Frac	Zipf Freq	Actual Diff	Pct Diff
1	aaaahh	48	1/1	48.00	0.00	100.00%
2	know	47	1/2	24.00	23.00	195.83%
3	love	45	1/3	16.00	29.00	281.25%
4	like	40	1/4	12.00	28.00	333.33%
5	never	36	1/5	9.60	26.40	375.00%
6	need	34	1/6	8.00	26.00	425.00%
7	time	34	1/7	6.86	27.14	495.83%
8	feel	33	1/8	6.00	27.00	550.00%
9	woman	33	1/9	5.33	27.67	618.75%
10	take	32	1/10	4.80	27.20	666.67%
11	hand	29	1/11	4.36	24.64	664.58%
12	long	26	1/12	4.00	22.00	650.00%
13	alone	25	1/13	3.69	21.31	677.08%
14	life	25	1/14	3.43	21.57	729.17%
15	back	24	1/15	3.20	20.80	750.00%
16	aahh	24	1/16	3.00	21.00	800.00%
17	mind	23	1/17	2.82	20.18	814.58%
18	right	22	1/18	2.67	19.33	825.00%
19	nothing	22	1/19	2.53	19.47	870.83%
20	hard	22	1/20	2.40	19.60	916.67%
21	make	21	1/21	2.29	18.71	918.75%
22	good	21	1/22	2.18	18.82	962.50%
23	there	21	1/23	2.09	18.91	1006.25%
24	tell	20	1/24	2.00	18.00	1000.00%
25	really	18	1/25	1.92	16.08	937.50%
26	could	18	1/26	1.85	16.15	975.00%
27	baby	18	1/27	1.78	16.22	1012.50%
28	hell	18	1/28	1.71	16.29	1050.00%
29	lady	18	1/29	1.66	16.34	1087.50%
30	hear	17	1/30	1.60	15.40	1062.50%
31	lover	17	1/31	1.55	15.45	1097.92%
32	find	17	1/32	1.50	15.50	1133.33%
33	anya	16	1/33	1.45	14.55	1100.00%
34	that	16	1/34	1.41	14.59	1133.33%
35	when	16	1/35	1.37	14.63	1166.67%
36	night	16	1/36	1.33	14.67	1200.00%
37	want	16	1/37	1.30	14.70	1233.33%
38	well	16	1/38	1.26	14.74	1266.67%
39	touch	16	1/39	1.23	14.77	1300.00%
40	oooooo	16	1/40	1.20	14.80	1333.33%
41	hush	16	1/41	1.17	14.83	1366.67%
42	heart	15	1/42	1.14	13.86	1312.50%
43	thing	15	1/43	1.12	13.88	1343.75%

Prawo Zipfa dla zespołu Deep Purple

```python
def _create_zipf_table(frequencies):
    zipf_table = []
    top_frequency = frequencies[0][1]

    for index, item in enumerate(frequencies, start=1):

        relative_frequency = "1/{}".format(index)
        zipf_frequency = top_frequency * (1 / index)
        difference_actual = item[1] - zipf_frequency
        difference_percent = (item[1] / zipf_frequency) * 100

        zipf_table.append({"word": item[0],
                           "actual_frequency": item[1],
                           "relative_frequency": relative_frequency,
                           "zipf_frequency": zipf_frequency,
                           "difference_actual": difference_actual,
                           "difference_percent": difference_percent})

    return zipf_table
```

Jedna z metod obliczających zgodność z prawem Zipfa